

سیستم مینی کانتینر - گزارش فنی

۱. مقدمه

این گزارش فنی پیاده‌سازی سیستم مینی کانتینر مشابه داکر را توصیف می‌کند که به عنوان پروژه درس سیستم‌عامل طراحی شده است. سیستم از C به ++C تبدیل شده و مفاهیم اصلی سیستم‌عامل شامل ایزولاسیون فرایند، مدیریت منابع هسته و فراخوانی‌های سیستمی را نشان می‌دهد، در حالی که روش‌های برنامه‌نویسی مدرن ++C را به نمایش می‌گذارد.

۲. معماری سیستم

سیستم به کامپوننت‌های مدولار سازماندهی شده است که هر کدام جنبه خاصی از کانتینری‌سازی را مدیریت می‌کنند. پیاده‌سازی ++C API سازگار با C را برای عملیات سطح سیستم حفظ می‌کند در حالی که ویژگی‌های مدرن ++C را برای بهبود مدیریت حافظه و ایمنی کد معرفی می‌کند.

۲.۱ کامپوننت‌های اصلی

- مدیریت‌کننده کانتینر: عملیات چرخه حیات کانتینر را هماهنگ می‌کند
- مدیریت‌کننده فضای نام: فضای نام لینوکس را برای ایزولاسیون فرایند مدیریت می‌کند
- مدیریت‌کننده منابع: محدودیت‌های CPU و حافظه را با استفاده از cgroups کنترل می‌کند
- مدیریت‌کننده فایل‌سیستم: ایزولاسیون فایل‌سیستم را از طریق pivot_root فراهم می‌کند
- رابط CLI: رابط خط فرمان برای تعامل کاربر
- وب سرور: رابط وب برای مانیتورینگ کانتینرها

۲.۲ تعامل کامپوننت‌ها

رابط CLI

↓

مدیریت‌کننده کانتینر ↔ مدیریت‌کننده منابع

↓

↔ مدیریت‌کننده فایل‌سیستم

مدیریت‌کننده فضای نام

۳. ایزولاسیون فرایند

۳.۱ مفاهیم فضای نام

- فضای نام (namespace) PID: شناسه فرایندها را ایزوله می‌کند و به هر کانتینر درخت فرایند خود را از PID ۱ می‌دهد
- فضای نام (namespace) Mount: نقاط mount فایل سیستم را ایزوله می‌کند و امکان جداول mount خصوصی را می‌دهد
- فضای نام (namespace) Network: رابط‌های شبکه، جداول مسیریابی و قوانین فایروال را ایزوله می‌کند
- فضای نام (namespace) User: نگاشت‌های شناسه کاربر و گروه را ایزوله می‌کند

۳.۲ جزئیات پیاده‌سازی

مدیریت‌کننده فضای نام از فراخوانی سیستمی `clone()` با پرچم‌های فضای نام استفاده می‌کند:

```
pid_t pid = clone(child_func, stack, CLONE_NEWPID | CLONE_NEWNS, args);
```

جنبه‌های کلیدی پیاده‌سازی:

- **تخصیص پشته:** فرایندهای فرزند نیاز به فضای پشته خود دارند
- **تنظیم فضای نام:** تابع فرزند ایزولاسیون را پس از ایجاد فضای نام پیکربندی می‌کند
- **فضای نام PID:** ایزولاسیون شناسه فرایند از PID ۱ فراهم می‌کند
- **فضای نام Mount:** امکان نمایش‌های خصوصی فایل سیستم را می‌دهد

۳.۳ پیوستن به فضای نام

برای اجرای دستورات در کانتینرهای موجود، سیستم به فضای نام موجود می‌پیوندد:

```
int namespace_join(pid_t target_pid, int ns_type) {  
}
```

۴. گروه‌های کنترل (cgroups) - مدیریت منابع

۴.۱ مفاهیم Cgroup

گروه‌های کنترل محدودیت‌های سلسله مراتبی منابع و حسابداری فراهم می‌کنند:

- کنترل CPU: استفاده از CPU را از طریق shares و quotas محدود می‌کند
- کنترل حافظه: استفاده از حافظه را با محدودیت‌های سخت و کنترل swap محدود می‌کند
- سلسله مراتب: ساختار درختی امکان کنترل منابع تو در تو را می‌دهد
- حسابداری: استفاده از منابع را برای هر گروه ردیابی می‌کند

۴.۲ جزئیات پیاده‌سازی

مدیریت‌کننده منابع با فایل سیستم `sys/fs/cgroup/` تعامل می‌کند:

```
// create cgroup
mkdir("/sys/fs/cgroup/cpu/mini_container/container_id", 0755);

// setup CPU shares
FILE *fp = fopen("/sys/fs/cgroup/cpu/mini_container/container_id/cpu.shares", "w");
fprintf(fp, "%d\n", shares);

// add process to cgroup
fp = fopen("/sys/fs/cgroup/cpu/mini_container/container_id/tasks", "w");
fprintf(fp, "%d\n", pid);
```

۴.۳ محدودیت‌های منابع

- CPU Shares: (پیش‌فرض: ۱۰۲۴) وزن نسبی برای زمان‌بندی CPU
- CPU Quota: (میکروثانیه در هر دوره) CPU محدودیت‌های مطلق زمان
- محدودیت‌های حافظه: محدودیت‌های سخت حافظه به بایت
- محدودیت‌های Swap: کنترل فضای swap

۵. ایزولاسیون فایل سیستم

۵.۱ Pivot Root

سیستم از `pivot_root()` برای ایزولاسیون فایل سیستم استفاده می‌کند که روش مدرن‌تر و امن‌تر است:

- `pivot_root()`: کردن فایل سیستم ریشه قدیمی را می‌دهد unmount امکان
- امنیت بیشتر: نسبت به `chroot` امن‌تر است
- کنترل بهتر: امکان مدیریت کامل فایل سیستم ریشه

۵.۲ پیاده‌سازی

```
int fs_setup_pivot_root(const char *new_root, const char *put_old) {
    // mount new root
    mount(new_root, new_root, "bind", MS_BIND | MS_REC, NULL);

    // create put_old directory
    mkdir(put_old, 0755);

    // pivot root
    syscall(SYS_pivot_root, new_root, put_old);

    // change to new root
    chdir("/");

    // unmount old root
    umount2(put_old, MNT_DETACH);
    rmdir(put_old);
}
```

۵.۳ ایجاد فایل سیستم ریشه

سیستم فایل سیستم‌های ریشه کانتینر حداقل ایجاد می‌کند:

- دایرکتوری‌های ضروری: `bin`, `/lib`, `/proc`, `/sys`, `/dev`
- گره‌های دستگاه: `dev/null`, `/dev/zero`, `/dev/random`
- فایل‌های پیکربندی پایه: `etc/passwd`, `/etc/group`

۶. فراخوانی‌های سیستمی و تعامل با هسته

۶.۱ فراخوانی‌های سیستمی اصلی

- `clone()`: فرایندهای جدید را در فضای نام ایجاد می‌کند
- `unshare()`: فرایندهای موجود را به فضای نام جدید منتقل می‌کند
- `pivot_root()`: تعویض ریشه پیشرفته و امن
- `mount()`: فایل سیستم mount عملیات

۶.۲ رابط مستقیم هسته

بر خلاف داکر، این سیستم به طور مستقیم با موارد زیر تعامل می‌کند:

- `/sys/fs/cgroup` برای مدیریت منابع
- `/proc/<pid>/ns/` برای عملیات فضای نام

- فراخوانی‌های سیستمی بدون تجرید سطح بالا

۷. مدیریت چرخه حیات کانتینر

۷.۱ وضعیت‌های کانتینر

- **CREATED**: کانتینر تعریف شده اما در حال اجرا نیست
- **RUNNING**: فرایند کانتینر فعال است
- **STOPPED**: فرایند کانتینر خاتمه یافته
- **DESTROYED**: منابع کانتینر پاکسازی شده

۷.۲ عملیات چرخه حیات

- **Create**: فضای نام، فایل سیستم `cgroups`، تنظیم
- **Run** (`Create + Start`): ایجاد و راه‌اندازی بلافاصله کانتینر
- **Start**: راه‌اندازی فرایند کانتینر با ایزولاسیون (برای کانتینرهای متوقف شده)
- **Stop**: `graceful` خاتمه فرایند کانتینر به طور
- **Destroy**: پاکسازی همه منابع

۷.۳ ذخیره‌سازی پیکربندی

سیستم پیکربندی کانتینرها را ذخیره می‌کند تا امکان `restart` کانتینرهای متوقف شده فراهم شود:

- `saved_config`: ذخیره می‌شود `container_info_t` پیکربندی کامل کانتینر در
- **Restart**: کانتینرهای متوقف شده می‌توانند با همان پیکربندی قبلی دوباره راه‌اندازی شوند